

$$b_w, b_b = \varnothing$$

درمیان

درمیان وزن ها در این epoch

$$\text{forward : } a_1' = g(x_1 w_{11}' + x_2 w_{12}' + b_1') = 0,5$$

$$a_2' = g(x_1 w_{21}' + x_2 w_{22}' + b_2') = 0,5$$

$$a_1^2 = g(a_1' w_{11}^2 + a_2' w_{12}^2 + b_1^2) = 0,5$$

backward :

$$\frac{dL}{dw_{11}'} = \underbrace{\frac{dL}{dz_1'}}_{\delta_1'} \cdot \underbrace{\frac{dz_1'}{dw_{11}'}}_{x_1} = (a_1' - y_1) \cdot x_1 = (0,5 - y_1) x_1$$

$$\frac{dL}{dw_{12}'} = \underbrace{\frac{dL}{dz_1'}}_{\delta_1'} \cdot \underbrace{\frac{dz_1'}{dw_{12}'}}_{x_2} = (a_1' - y_1) \cdot x_2 = (0,5 - y_1) \cdot x_2$$

$$\frac{dL}{dw_{21}'} = \underbrace{\frac{dL}{dz_2'}}_{\delta_2'} \cdot \underbrace{\frac{dz_2'}{dw_{21}'}}_{x_1} = (a_2' - y_2) x_1 = (0,5 - y_2) \cdot x_1$$

$$\frac{dL}{dw_{22}'} = \underbrace{\frac{dL}{dz_2'}}_{\delta_2'} \cdot \underbrace{\frac{dz_2'}{dw_{22}'}}_{x_2} = (a_2' - y_2) x_2 = (0,5 - y_2) x_2$$

$$\frac{\partial L}{\partial w_{11}^2} = \frac{\partial L}{\partial z_1^2} \cdot \frac{\partial z_1^2}{\partial w_{11}^2} = (\underbrace{a_1^2}_{\delta_1^2} - \underbrace{y_1}_{a_1'}) a_1' = \frac{0.5 - y_1}{2}$$

$$\frac{\partial L}{\partial w_{12}^2} = \frac{\partial L}{\partial z_1^2} \cdot \frac{\partial z_1^2}{\partial w_{12}^2} = (\underbrace{a_1^2}_{\delta_1^2} - \underbrace{y_1}_{a_1'}) a_2' = \frac{0.5 - y_1}{2}$$

update :

$$D_{11}^1 = \frac{1}{m} \cdot \frac{\partial L}{\partial w_{11}^1} + \underbrace{\frac{\lambda}{m}}_{\gamma_0} w_{11}^1 = \frac{1}{m} (0.5 - y_1) x_1$$

$$D_{12}^1 = \frac{1}{m} \cdot \frac{\partial L}{\partial w_{12}^1} + 0 = \frac{1}{m} (0.5 - y_1) x_2$$

$$D_{21}^1 = \frac{1}{m} \cdot \frac{\partial L}{\partial w_{21}^1} = \frac{1}{m} (0.5 - y_2) x_1$$

$$D_{22}^1 = \frac{1}{m} \cdot \frac{\partial L}{\partial w_{22}^1} = \frac{1}{m} (0.5 - y_2) x_2$$

$$D_{11}^2 = \frac{1}{m} \cdot \frac{\partial L}{\partial w_{11}^2} = \frac{1}{2m} (0.5 - y_1)$$

$$D_{12}^2 = \frac{1}{m} \cdot \frac{\partial L}{\partial w_{12}^2} = \frac{1}{2m} (0.5 - y_1)$$

$$w_{11}^1 = \tilde{w}_{11}^1 - \alpha D_{11}^1 = -\frac{\alpha}{m} (0.5 - y_1) x_1$$

$$w_{12}^1 = \tilde{w}_{12}^1 - \alpha D_{12}^1 = -\frac{\alpha}{m} (0.5 - y_1) x_2$$

$$w_{21}^1 = \tilde{w}_{21}^1 - \alpha D_{21}^1 = -\frac{\alpha}{m} (0.5 - y_2) x_1$$

$$w_{22}^1 = \tilde{w}_{22}^1 - \alpha D_{22}^1 = -\frac{\alpha}{m} (0.5 - y_2) x_2$$

$$w_{11}^2 = \tilde{w}_{11}^2 - \alpha D_{11}^2 = -\frac{\alpha}{2m} (0.5 - y_1)$$

$$w_{12}^2 = \tilde{w}_{12}^2 - \alpha D_{12}^2 = -\frac{\alpha}{2m} (0.5 - y_1)$$

همانطور که مشخص است،
وزن ها update
می شوند و از صفر
تغییر می کنند.

له کیفیت بایس ها در پایان epoch اول :

backward : $\frac{dL}{db'_1} = \delta'_1 = a'_1 - y_1 = 0.5 - y_1$

$$\frac{dL}{db'_2} = \delta'_2 = a'_2 - y_2 = 0.5 - y_2$$

$$\frac{dL}{db^2_1} = \delta^2_1 = a^2_1 - y_1 = 0.5 - y_1$$

update : $B'_1 = \frac{1}{m} \frac{dL}{db'_1} = \frac{1}{m} (0.5 - y_1)$

$$B'_2 = \frac{1}{m} \frac{dL}{db'_2} = \frac{1}{m} (0.5 - y_2)$$

$$B^2_1 = \frac{1}{m} \frac{dL}{db^2_1} = \frac{1}{m} (0.5 - y_1)$$

$$b^1_1 = b'_1 - \alpha B'_1 = -\frac{\alpha}{m} (0.5 - y_1)$$

$$b^1_2 = b'_2 - \alpha B'_2 = -\frac{\alpha}{m} (0.5 - y_2)$$

$$b^2_1 = b^2_1 - \alpha B^2_1 = -\frac{\alpha}{m} (0.5 - y_1)$$

} \Rightarrow بایس ها نیز update شدند

لحساب صافي الربح في epoch ١

forward :
$$a_1' = g \left(-\frac{\alpha}{m} (0.5 - j_1) x_1^2 - \frac{\alpha}{m} (0.5 - j_1) x_2^2 - \frac{\alpha}{m} (0.5 - j_1) \right)$$

$$= g \left(-\frac{\alpha}{m} (0.5 - j_1) (x_1^2 + x_2^2 + 1) \right) = m_1 \Rightarrow$$
 (نماذج الربح صافي الربح)

$$a_2' = g \left(-\frac{\alpha}{m} (0.5 - j_2) x_1^2 - \frac{\alpha}{m} (0.5 - j_2) x_2^2 - \frac{\alpha}{m} (0.5 - j_2) \right)$$

$$= g \left(-\frac{\alpha}{m} (0.5 - j_2) (x_1^2 + x_2^2 + 1) \right) = m_2$$

$$a_1'' = g \left(-\frac{\alpha}{2m} (0.5 - j_1) g \left(-\frac{\alpha}{m} (0.5 - j_1) (x_1^2 + x_2^2 + 1) \right) \right.$$

$$\left. - \frac{\alpha}{2m} (0.5 - j_1) g \left(-\frac{\alpha}{m} (0.5 - j_1) (x_1^2 + x_2^2 + 1) \right) \right.$$

$$\left. - \frac{\alpha}{m} (0.5 - j_1) \right) = m_3$$

backward :
$$\frac{\partial L}{\partial w_{11}'} = (a_1' - j_1) \cdot x_1 = (m_1 - j_1) \cdot x_1$$

$$\frac{\partial L}{\partial w_{12}'} = (a_1' - j_1) x_2 = (m_1 - j_1) \cdot x_2$$

$$\frac{\partial L}{\partial w_{21}'} = (a_2' - j_2) x_1 = (m_2 - j_2) \cdot x_1$$

$$\frac{\partial L}{\partial w_{22}'} = (a_2' - j_2) x_2 = (m_2 - j_2) x_2$$

$$\frac{\partial L}{\partial w_{11}''} = (a_1'' - j_1) a_1' = (m_3 - j_1) \cdot m_1$$

$$\frac{\partial L}{\partial w_{12}''} = (a_1'' - j_1) a_2' = (m_3 - j_1) m_2$$

update: $D'_{11} = \frac{1}{m} \frac{dL}{d\omega'_{11}} + \frac{\lambda}{m} \omega'_{11} = \frac{1}{m} (m_1 - j_1) x_1 - \frac{\lambda \alpha}{m^2} (0.5 - j_1) x_1 = n_1$

$$D'_{12} = \frac{1}{m} \frac{dL}{d\omega'_{12}} + \frac{\lambda}{m} \omega'_{12} = \frac{1}{m} (m_1 - j_1) x_2 - \frac{\lambda \alpha}{m^2} (0.5 - j_1) x_2 = n_2$$

$$D'_{21} = \frac{1}{m} \frac{dL}{d\omega'_{21}} + \frac{\lambda}{m} \omega'_{21} = \frac{1}{m} (m_2 - j_2) x_1 - \frac{\lambda \alpha}{m^2} (0.5 - j_2) x_1 = n_3$$

$$D'_{22} = \frac{1}{m} \frac{dL}{d\omega'_{22}} + \frac{\lambda}{m} \omega'_{22} = \frac{1}{m} (m_2 - j_2) x_2 - \frac{\lambda \alpha}{m^2} (0.5 - j_2) x_2 = n_4$$

$$D^2_{11} = \frac{1}{m} \frac{dL}{d\omega^2_{11}} + \frac{\lambda}{m} \omega^2_{11} = \frac{1}{m} (m_3 - j_1) m_1 - \frac{\lambda \alpha}{2m^2} (0.5 - j_1) = n_5$$

$$D^2_{12} = \frac{1}{m} \frac{dL}{d\omega^2_{12}} + \frac{\lambda}{m} \omega^2_{12} = \frac{1}{m} (m_3 - j_1) m_2 - \frac{\lambda \alpha}{2m^2} (0.5 - j_1) = n_6$$

$$\omega'_{11} = \omega_{11} - \alpha D'_{11} = -\frac{\alpha}{m} (0.5 - j_1) x_1 - \alpha n_1$$

$$\omega'_{12} = \omega_{12} - \alpha D'_{12} = -\frac{\alpha}{m} (0.5 - j_1) x_2 - \alpha n_2$$

$$\omega'_{21} = \omega_{21} - \alpha D'_{21} = -\frac{\alpha}{m} (0.5 - j_2) x_1 - \alpha n_3$$

$$\omega'_{22} = \omega_{22} - \alpha D'_{22} = -\frac{\alpha}{m} (0.5 - j_2) x_2 - \alpha n_4$$

$$\omega^2_{11} = \omega^2_{11} - \alpha D^2_{11} = -\frac{\alpha}{2m} (0.5 - j_1) - \alpha n_5$$

$$\omega^2_{12} = \omega^2_{12} - \alpha D^2_{12} = -\frac{\alpha}{2m} (0.5 - j_1)$$

في epoch ١٠٠٠

$$\text{backward: } \frac{dL}{db'_1} = \delta'_1 = a'_1 - y_1 = m_1 - y_1$$

$$\frac{dL}{db'_2} = \delta'_2 = a'_2 - y_2 = m_2 - y_2$$

$$\frac{dL}{db^2_1} = \delta^2_1 = a^2_1 - y_1 = m_3 - y_1$$

$$\text{update: } B'_1 = \frac{1}{m} \frac{dL}{db'_1} = \frac{1}{m} (m_1 - y_1)$$

$$B'_2 = \frac{1}{m} \frac{dL}{db'_2} = \frac{1}{m} (m_2 - y_2)$$

$$B^2_1 = \frac{1}{m} \frac{dL}{db^2_1} = \frac{1}{m} (m_3 - y_1)$$

(همچون نام از بایس ها و وزن ها برابر هستند)

باز هم به محاسبات :

$$w_{11}^1 = w_{21}^1$$


$$w_{12}^1 = w_{22}^1$$

$$b_1^1 = b_2^1$$




بایس ها و وزن های نرون های
لایه اول، به صورت تغییر به نظیر با هم
برابر هستند.

باز هم به همین مسئله، می توانیم نرون های لایه ی ۱ را فقط با یک نرون
جایگزین کرد. شبکه عصبی معادل به این صورت می شود:



①

فاصله عمودی برای تشخیص این مقیاس بهتر است. چنانچه مقیاس target را روی محور عمودی مشخصات رسم کردیم. و فاصله‌ی مقدار تخمین زده شده و مقدار واقعی را باید نسبت به محور عمودی مشخصات بدست آوریم. و نشان بدهیم که برای یک مقدار مشخص، فاصله‌ی تخمین زده شده در واقع چقدر است.




②

Cost-function : $x^2 (\text{sgn}(x) + \alpha)^2$

\downarrow
 $-1 < \alpha < 0$

که این عدد را مقیاس انتخاب کنیم تا برای جریجه‌ی زیاده‌ریزی برای underestimation در نظر بگیریم.



این تابع، جریجه‌ی زیاده‌ریزی برای underestimation قرار می‌دهد. به عبارتی دیگر، برای همین حاکمان راحت خواهد بود که بیش از حد underestimate خواهد بود.

$$f(x, y) = \left(\frac{3}{4}x - \frac{3}{2}\right)^2 + (y-2)^2 + \frac{1}{4}xy$$

$$= \frac{9}{16}x^2 + y^2 + \frac{1}{4}xy - \frac{3}{4}x - 4y + \frac{25}{4}$$

$$\frac{df(x, y)}{dx} = \frac{9}{8}x + \frac{1}{4}y - \frac{3}{4}$$

$$\frac{df(x, y)}{dy} = 2y + \frac{1}{4}x - 4$$

gradient descent \leftarrow

repeat until convergence

$$x = x - \alpha \frac{df(x, y)}{dx} = x - \alpha \left(\frac{9}{8}x + \frac{1}{4}y - \frac{3}{4}\right)$$

$$y = y - \alpha \frac{df(x, y)}{dy} = y - \alpha \left(2y + \frac{1}{4}x - 4\right)$$

}

* مرحله اول : $\alpha = 0,01$ - نقطه شروع : $(5, 4)$

$$(5, 4) : f(5, 4) = \boxed{14,06}$$

$$1 \rightarrow x = 5 - (0,01) \left(\frac{45}{8} + 1 - \frac{3}{4}\right) = 4,96$$

$$\rightarrow (4,96, 3,97)$$

$$y = 4 - (0,01) \left(2 + \frac{5}{4} - 4\right) = 3,97$$

$$\Rightarrow f(4,96, 3,97) = \boxed{13,73}$$

2
⋮

در این حالت، اگر بخواهیم حین روند در حال پیشرفت است. مقدار f حین آن حین در حال کاهش است. که این نشان دهنده این است که مقدار x حین کوچک است. برای اینکه به مقدار حین نزدیک شویم، تعداد زیادی مرحله باید طی کنیم...

نقطه شروع: (5,4)

$$\alpha = 0,5$$

* مرحله دوم:

$$f(5,4) = \boxed{14,06}$$

$$1 \downarrow x = 5 - (0,5) \left(\frac{35}{4} \right) = 2,81$$

$$y = 4 - (0,5) \left(\frac{11}{4} \right) = 2,63$$

$$\Rightarrow f(2,81, 2,63) = \boxed{2,61}$$

$$2 \downarrow x = 2,81 - (0,5) (1,57) = 2,03$$

$$y = 2,63 - (0,5) (1,96) = 1,65$$

$$\Rightarrow f(2,03, 1,65) = \boxed{0,96}$$

$$3 \downarrow x = 2,03 - (0,5) (0,45) = 1,81$$

$$y = 1,65 - (0,5) (-0,19) = 1,75$$

$$\Rightarrow f(1,81, 1,75) = \boxed{0,874}$$

$$4 \downarrow x = 1,81 - (0,5) (0,22) = 1,7$$

$$y = 1,75 - (0,5) (-0,05) = 1,78$$

$$\Rightarrow f(1,7, 1,78) = \boxed{0,855}$$

$$5 \downarrow x = 1,7 - (0,5) (0,11) = 1,65$$

$$y = 1,78 - (0,5) (-0,02) = 1,79$$

$$\Rightarrow f(1,65, 1,79) = \boxed{0,851}$$

شرط continuity را این
ترتیب تعریف کردم، که وقتی
اضافه در f متغیرهای کمتر از
 5×10^{-3} شد، استوپ متوقف شود.

بنابراین، پس از 5 مرحله
متوقف می شود. مقدار min
را برای تابع f برابر $0,851$
بر می گرداند. که همان مقدار بهینه

است.

نقطه شروع: $(5, 4)$

* مرحله سوم: $\alpha = 0,75$

$$f(5, 4) = \boxed{14,06}$$

$$1 \downarrow x = 5 - (0,75) \left(\frac{35}{8} \right) = 1,72$$

$$y = 4 - (0,75) \left(\frac{11}{4} \right) = 1,94$$

$$f(1,72, 1,94) = \boxed{0,881}$$

$$2 \downarrow x = 1,72 - (0,75) (0,17) = 1,59$$

$$y = 1,94 - (0,75) (0,31) = 1,71$$

$$f(1,59, 1,71) = \boxed{0,858}$$

$$3 \downarrow x = 1,59 - (0,75) (-0,03) = 1,61$$

$$y = 1,71 - (0,75) (-0,18) = 1,85$$

$$f(1,61, 1,85) = \boxed{0,852}$$

$$4 \downarrow x = 1,61 - (0,75) (0,02) = 1,60$$

$$y = 1,85 - (0,75) (0,10) = 1,78$$

$$f(1,60, 1,78) = \boxed{0,850}$$

↓
ایستادم از جدول شرط Contingency

که در قسمت قبل تعیین کرده بودم،
استفاده کردن برای توقف آزمون

↓

در این حالت، پس از 4 مرحله

مقدار بحرانی $0,850$ حاصل
شد. که نشان می دهد که با تعداد

مرحله ای کمتر، مقدار بحرانی بدست
آوردم نسبت به قسمت قبل. که

پس نشان می دهد که α متغیر که کوچکتر
بود، روند کند تر داشت. و این

α مناسب تر است.

(4)

الف) تغییرات در f_1 منبیه آهسته در حال رخ دادن است. مقدار f_1 ، ضمیمه آهسته دارد پس می آید. این نشان دهنده این است که فیلتر کوچک است. که در این حالت،

مادر خطای \min خواهیم رسید؛ و سی زمان زیادی طول خواهد کشید.


ب) تغییرات در f_2 نظم یکنواختی ندارد و گاهی مقدار آن کمتر و گاهی بیشتر می شود. این نشان می دهد که مقدار α چینی بزرگ است.

ج) تغییرات در f_3 با سرعت خوبی به کاشی است. که این نشان می دهد مقدار α صاف است.

د) تغییرات f_4 به سرعت کاشی است و سرعت خوبی هم دارد. که نشان می دهد مقدار α مناسب است.

5

* مثال: یک سری ایمیل داریم. می‌خواهیم آن‌ها را
در دو دسته‌ی spam و non-spam دسته‌بندی کنیم.
دسته‌ی X نشان‌دهنده‌ی spam است و O نشان‌دهنده‌ی
non-spam است.



بررسی می‌کنیم که در این مثال باید به داده‌ها بدیم، مسئله است. در linear regression بررسی می‌کنیم که به داده‌ها اختصاص می‌دهیم و می‌تونه بود. پس این مسئله با linear regression قابل حل نیست.


در مسائل linear regression سعی داشتیم تا دسته روی داده‌ها قرار دهیم و محل قرارگیری آن‌ها را در فضا روی نمودار مشخص کنیم. ولی چنین کاری با این سوال مقادیر است. هدف پیدا کردن یک اسکالریست. بلکه هدف جدا سازی در نوع از داده‌ها و دسته‌بندی آن‌هاست.

تفاوت اصلی linear regression و logistic regression در مسئله یا گفته بودن بررسی می‌کنیم. است. که چون در این مثال مسئله باید با logistic regression آن را حل کنیم.

(6)

الف) $g(z) = \frac{1}{1+e^{-z}}$ $\rightarrow \frac{dg(z)}{dz} = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}}$

$$\frac{dg(z)}{dz} = g(z) \cdot (1 - g(z))$$



1- Binary step function

(6) ب


تعریف این تابع به این شکل

$$f(x) = \begin{cases} 1 & , x \geq 0 \\ 0 & , x < 0 \end{cases}$$

- همانطور که مشخص است، این تابع zero-centered نیست.

- اما ویژگی دیگری که دارد این است که گرادینت آن برابر صفر است؛ چنان

همانطور که از نمودار آن نیز مشخص است، وابسته به x نیست.



2- linear function


$$f(x) = ax$$

- این تابع، همانطور که از نمودارش مشخص است، zero-centered نیست.

- در باره گرادینت؛ درست است که گرادینت آن برابر صفر است، اما برابر a

است، که عددی "کامل" نامیده می شود به x است. بنابراین، گرادینت


خوب نیست.



3- Sigmoid :

$$f(x) = \frac{1}{1 + e^{-x}}$$

- مشتق این تابع را در بخش قبل دیدیم. این تابع، از حدی نقاط مشتق پذیر است.



مقادیر گزینایی ها، در بازه‌های


3 تا 3، تفاوت قابل توجهی بهم

دارند. در نقطه نقطه حالت flat دارد.

این یعنی در مقادیر بسیار 3 یا کمتر از 3، مشتق به صفر نزدیک می‌شود.

- به علاوه، این function، zero-centered نیست.

4- Tanh :




تغییرات این تابع :

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

- همانطور که مشخص است، zero-centered است.

- به عبارتی مورد، بقیه ویژگی‌های آن مانند کات است. پیوسته است و



همه جا مشتق پذیر است.

ویژگی‌های مشتق آن،

مانند کات است.

همچنین به خاطر zero-centered بودن، نسبت به کات ترجیح داده می‌شود.




5- ReLU :

تعریف : $f(x) = \max(0, x)$

- این تابع ، zero-centered نیست .



- برای x های منفی ، مشتق برابر 0 است



6- Leaky ReLU :

تعریف :
$$f(x) = \begin{cases} 0.01x & , x < 0 \\ x & , x \geq 0 \end{cases}$$

- تفاوتی که با ReLU دارد این است که : مشتق برای x های منفی برابر 0.01 است ؛

بلکه برابر 0.01 است .

* تعدادی activation function دیگر نیز وجود دارد که نکته محدودیت هستند .

حالا بررسی کنیم که کدام یکی بهتر است :

- تابع sigmoid ، متغیرات آن برای classify کردن بسیار مناسب اند

- تابع sigmoid و tanh گاهی به دلیل vanishing gradient مورد استفاده قرار نمی گیرند

- ReLU که تابع محوره است که برای شبکه های عمیق امروزه کاربرد دارد

- اگر می خواهیم نرون های عمیق را بسازیم ، Leaky ReLU گزینه خوبی است .

پس واضح است که برای logistic regression ، در تابع Sigmoid و Tanh بهترین

گزینه ها هستند . ولی همانطور که گفتیم ، Tanh به خاطر zero-centered بودن ،

به Sigmoid ترجیح داده می شود

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^i \log h_{\theta}(x^i) - (1-y^i) \log (1-h_{\theta}(x^i))] \\ = \frac{1}{m} \sum_{i=1}^m T_i$$

↓
 "Cost" term
 regularization
 term

$$\Rightarrow \frac{dJ(\theta)}{d\theta_j} = \frac{1}{m} \sum \frac{dT_i}{d\theta_j} = ?$$

$$T_i = - [y^i \log h_{\theta}(x^i) + (1-y^i) \log (1-h_{\theta}(x^i))]$$

$$h_{\theta}(x^i) = \sigma(\theta^T x^i) = \sigma(z^i)$$

$$\Rightarrow \frac{dT_i}{d\theta_j} = \frac{dT_i}{d\sigma(z^i)} \times \frac{d\sigma(z^i)}{dz^i} \times \frac{dz^i}{d\theta_j}$$

$$\Rightarrow \frac{dT_i}{d\sigma(z^i)} = - \left[\frac{y^i}{\sigma(z^i)} - \frac{1-y^i}{1-\sigma(z^i)} \right]$$

$$\Rightarrow \frac{d\sigma(z^i)}{dz^i} = \frac{e^{-z^i}}{(1+e^{-z^i})^2} = \sigma(z^i) \cdot (1-\sigma(z^i))$$

$$\sigma(z^i) = \frac{1}{1+e^{-z^i}}$$

درواز
 طاق قتیبه
 ۱/(۱+e^{-x})
 ~

$$\Rightarrow \frac{dz^i}{d\theta_j} = x_j^i$$

$$\Rightarrow \frac{dT_i}{d\theta_j} = [\sigma(z^i) - y^i] \cdot x_j^i$$

$$\Rightarrow \frac{dJ(\theta)}{d\theta_j} = \frac{1}{m} \sum_{i=1}^m [\sigma(z^i) - y^i] \cdot x_j^i$$


حالت $J(\theta)$ را با وجود نرم regularization در نظر می‌گیریم

$$* \frac{dJ(\theta)}{d\theta_j} = \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^i) - y^i] \cdot x_j^i \cdot 2\lambda \theta_j \quad (j=0, 1, 2)$$

داریم: $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$

وقتی مقدار λ را خیلی بزرگ در نظر بگیریم، مقدار θ ای که در نرم regularization $(\lambda \theta_j^2)$ حضور دارد برابر صفر می‌شود. حال باید بررسی کنیم که با منسخت شدن هر یک از θ ها $(j=0, 1, 2)$ چه

تفسیری در خطای آموزش می‌دهد.



+ اگر θ_0 برابر صفر نشود: $h_{\theta}(x) = g(\theta_1 x_1 + \theta_2 x_2)$


در این صورت، هر چه تقسیم خطا از نقطه $(0,0)$ عبور

می‌کند. که با توجه به این محدودیت، خطای آموزش زیاد خواهد شد.

+ اگر θ_1 یا θ_2 برابر صفر شود، مدل از این هم ساده‌تر و محدودتر می‌شود. (احتمالاً سواری یکی از معادلات خواهد شد). بنابراین، خطای آموزش در این دو حالت، از حالت قبلی هم بیشتر می‌شود.

بنابراین، ما با داشتن فقط θ_0 ، $(\theta_0, \theta_1, \theta_2)$ در خطی داریم مدل ضعیف ساده‌ای است. وقتی از این θ ها کم‌کم کم، مدل ضعیف ساده‌تر می‌شود و خطای آن زیاد می‌شود.

tan-sigmoid :



(8)

$$\text{weights : } \begin{cases} a^1 = \text{tanSig}(\omega^1 p + b^1) = \text{tanSig}(2) \approx 1 \\ a^2 = \text{tanSig}(\omega^2 a^1 + b^2) = \text{tanSig}(-1) \approx -1 \end{cases}$$

$$\frac{dL}{d\omega_1} = \frac{dL}{dz_1} \cdot \frac{dz_1}{d\omega_1} = \delta^1 \cdot p = (a^1 - y_1) p = (1 - y_1) p$$

$$\frac{dL}{d\omega_2} = \frac{dL}{dz_2} \cdot \frac{dz_2}{d\omega_2} = \delta^2 \cdot a^1 = (a^2 - y_2) a^1 = -(y_2 + 1)$$

$$\frac{dL}{db_1} = \delta^1 = a^1 - y_1 = 1 - y_1$$

$$\frac{dL}{db_2} = \delta^2 = a^2 - y_2 = -(1 + y_2)$$

$$D^1 = \frac{1}{m} \frac{dL}{d\omega^1} + \frac{\lambda}{m} \omega^1 = \frac{(1 - y_1)p - \lambda}{m}$$

$$D^2 = \frac{1}{m} \frac{dL}{d\omega^2} + \frac{\lambda}{m} \omega^2 = \frac{-(y_2 + 1) - 2\lambda}{m}$$

$$B^1 = \frac{1}{m} \frac{dL}{db^1} = \frac{1 - y_1}{m}$$

$$B^2 = \frac{1}{m} \frac{dL}{db^2} = \frac{-(1 + y_2)}{m}$$

$$\omega_1 = \omega_1 - \alpha D_1 = -1 - \alpha \frac{(1 - y_1)p - \lambda}{m}$$

$$\omega_2 = \omega_2 - \alpha D_2 = -2 - \alpha \frac{-(y_2 + 1) - 2\lambda}{m}$$

$$b^1 = b^1 - \alpha B^1 = 1 - \alpha \frac{1 - y_1}{m}$$

$$b^2 = b^2 - \alpha B^2 = 1 - \alpha \frac{-(1 + y_2)}{m}$$

(9)

(الف)

$$\frac{dL}{dn^2} = a^2 - y = \delta^2$$

$$\frac{dL}{db^2} = \delta^2$$

$$\frac{dL}{d\omega^2} = \delta^2 \cdot a'$$

$$\frac{dL}{d\omega^{2,1}} = \delta^2 \cdot p$$

$$\frac{dL}{dn'} = a' - y = \delta'$$

$$\frac{dL}{db'} = \delta'$$

$$\frac{dL}{d\omega'} = \delta' \cdot p$$

$$\left(\delta' = [(\omega^2)^T \delta^2] \cdot * f'(n') \right)$$

← آيزيت كرون باراسترحا:

$$D^1 = \frac{1}{m} \cdot \frac{dL}{d\omega'} = \frac{1}{m} (a' - y) \cdot p = \frac{1}{m} [f'(w'p + b') - y] \cdot p$$

$$D^2 = \frac{1}{m} \cdot \frac{dL}{d\omega^2} = \frac{1}{m} (a^2 - y) \cdot a' = \frac{1}{m} [f^2(w^2a' + w^{2,1}p + b^2) - y] \cdot a'$$

$$D^{2,1} = \frac{1}{m} \cdot \frac{dL}{d\omega^{2,1}} = \frac{1}{m} (a^2 - y) \cdot p = \frac{1}{m} [f^2(w^2a' + w^{2,1}p + b^2) - y] \cdot p$$

$$B^1 = \frac{1}{m} \cdot \frac{dL}{db'} = \frac{1}{m} \delta' = \frac{1}{m} [a' - y] = \frac{1}{m} [f'(w'p + b') - y]$$

$$B^2 = \frac{1}{m} \cdot \frac{dL}{db^2} = \frac{1}{m} \delta^2 = \frac{1}{m} [a^2 - y] = \frac{1}{m} [f^2(w^2a' + w^{2,1}p + b^2) - y]$$

$$w_1 = w_1 - \alpha D^1 = w_1 - \frac{\alpha}{m} [f'(w'p + b') - y] \cdot p$$

$$w_2 = w_2 - \alpha D^2 = w_2 - \frac{\alpha}{m} [f^2(w^2a' + w^{2,1}p + b^2) - y] \cdot a'$$

$$w^{2,1} = w^{2,1} - \alpha D^{2,1} = w^{2,1} - \frac{\alpha}{m} [f^2(w^2a' + w^{2,1}p + b^2) - y] \cdot p$$

$$b^1 = b^1 - \alpha B^1 = b^1 - \frac{\alpha}{m} [f'(w'p + b') - y]$$

$$b^2 = b^2 - \alpha B^2 = b^2 - \frac{\alpha}{m} [f^2(w^2a' + w^{2,1}p + b^2) - y]$$

② (ب) افتادن کرن مرتب منظم ساری، برزول D^l اثر خواهد داشت :

$$D^1 = \frac{1}{m} \frac{dL}{d\omega^1} + \frac{\lambda}{m} \omega^1 = \frac{1}{m} [f'(w^1 p + b^1) - y] \cdot p + \frac{\lambda}{m} \omega^1$$

$$D^2 = \frac{1}{m} \cdot \frac{dL}{d\omega^2} + \frac{\lambda}{m} \omega^2 = \frac{1}{m} [f^2(w^2 a^1 + w^{2,1} p + b^2) - y] \cdot a^1 + \frac{\lambda}{m} \omega^2$$

$$D^{2,1} = \frac{1}{m} \cdot \frac{dL}{d\omega^{2,1}} + \frac{\lambda}{m} \omega^{2,1} = \frac{1}{m} [f^2(w^2 a^1 + w^{2,1} p + b^2) - y] \cdot p + \frac{\lambda}{m} \omega^{2,1}$$

$$\omega_1 = \omega_1 - \alpha D^1 = \omega^1 - \frac{\alpha}{m} [(f'(w^1 p + b^1) - y) \cdot p + \lambda \omega^1]$$

$$\omega_2 = \omega_2 - \alpha D^2 = \omega^2 - \frac{\alpha}{m} [(f^2(w^2 a^1 + w^{2,1} p + b^2) - y) \cdot a^1 + \lambda \omega^2]$$

$$\omega^{2,1} = \omega^{2,1} - \alpha D^{2,1} = \omega^{2,1} - \frac{\alpha}{m} [(f^2(w^2 a^1 + w^{2,1} p + b^2) - y) \cdot p + \lambda \omega^{2,1}]$$

← با توجه به اینکه D^l تغییر می کند، ω^l نیز نسبت به حالت قبل عوض می شود

در B^l عوض نمی شود ← b^l مانند حالت قبل خواهد بود.